



Universidad Autónoma de Baja California

Facultad de Ingeniería, Arquitectura y Diseño

Programa Educativo en Ingeniería Electrónica



Desarrollo de un sistema multimodal para la interpretación de Lengua de Señas Mexicana a voz y texto

Tarea académica: Búsqueda, caracterización y análisis exploratorio de cinco (5) datasets públicos

Presenta:

Valeria Aguilar Meza

Director de tesis:

Dr. Everardo Inzunza Gonzalez

Resumen ejecutivo. Este documento presenta la búsqueda, caracterización y análisis exploratorio (EDA) de cinco conjuntos de datos públicos pertinentes al desarrollo de un sistema multimodal de interpretación de la Lengua de Señas Mexicana (LSM). Los datasets seleccionados —tres de imágenes estáticas, uno de videos dinámicos del alfabeto y un corpus paralelo de glosas español-LSM— se caracterizan siguiendo el esquema *Datasheets for Datasets* (Gebru et al., 2021) y los principios FAIR (Wilkinson et al., 2016). Para cada conjunto se documenta autoría, licencia, especificaciones técnicas, organización, etiquetas, particiones, EDA con visualizaciones reproducibles, estadística descriptiva con prueba de normalidad e intervalos de confianza al 95 %, casos de uso publicados en revistas JCR y conferencias IEEE/Springer en los últimos cinco años, y limitaciones. El análisis comparativo concluye que la combinación del corpus de Montesinos como dataset principal y del corpus de glosas Lara-Ortiz *et al.* (2025) como dataset complementario maximiza la cobertura de los componentes manuales y lingüísticos requeridos. Se justifica además que el preprocesamiento basado en MediaPipe Holistic, al sustituir los tensores RGB por vectores de *keypoints*, reduce la dimensionalidad de entrada y habilita el despliegue del modelo en hardware embebido de bajo consumo.

Contents

1	Contexto del tema de tesis	2
1.1	Problema, pregunta y objetivos	2
1.2	Justificación del enfoque y del uso de datasets públicos	2
1.3	Metodología de búsqueda y criterios de selección	2
2	Fichas técnicas de los cinco datasets seleccionados	3
2.1	D1 · Lengua de Señas Mexicana (~100 000 fotos) — Montesinos	3
2.2	D2 · LSM Lenguaje de señas mexicanas — Chacon Quintero <i>et al.</i>	4
2.3	D3 · Mexican Sign Language Dataset — warcoder	5
2.4	D4 · MSL Alphabet (dynamic only) — Sánchez-Vicinaiz <i>et al.</i>	6
2.5	D5 · Spanish to MSL glosses corpus — Lara-Ortiz <i>et al.</i>	7
3	Análisis comparativo entre los cinco datasets	9
3.1	Tabla comparativa con criterios homogéneos	9
3.2	Lectura crítica	9
3.3	Recomendación final	9
4	Reflexión y plan de uso	10
4.1	Integración de los datasets en el <i>pipeline</i> de la tesis	10
4.2	Validación cruzada y métricas	10
4.3	Limitaciones, sesgos y consideraciones éticas globales	10
4.4	Conclusión	10

1 Contexto del tema de tesis

1.1 Problema, pregunta y objetivos

La Lengua de Señas Mexicana (LSM) es la lengua materna de una proporción significativa de la población sorda en México, estimada en 2.3 millones de personas con discapacidad auditiva según el Censo INEGI 2020 (Instituto Nacional de Estadística y Geografía, 2020). Reconocida como patrimonio lingüístico nacional desde 2005, la LSM carece sin embargo de herramientas asistivas comparables a las disponibles para la Lengua de Señas Americana (Sánchez-Vicinaiz et al., 2024). Por su naturaleza viso-gestual, la interpretación correcta requiere analizar configuración manual, expresiones faciales, dirección de mirada y postura corporal —marcadores no manuales con función gramatical (Serafín de Fleischmann and González Pérez, 2011)—, lo que entra en tensión con los recursos limitados del hardware embebido portátil.

La pregunta de investigación se formula así: *¿cómo diseñar un sistema multimodal de interpretación de LSM que, al sustituir el procesamiento de video crudo por la extracción de descriptores morfológicos (keypoints), reduzca la carga computacional lo suficiente para operar en dispositivos electrónicos con recursos limitados sin sacrificar precisión?*

El **objetivo general** es desarrollar un sistema de interpretación multimodal basado en aprendizaje profundo capaz de traducir LSM a voz y texto, optimizado para hardware portátil de bajo consumo. Los **objetivos específicos** son: (1) caracterizar cinco datasets públicos de LSM con rigor estadístico y respaldo bibliográfico JCR/IEEE/Springer reciente; (2) implementar un *pipeline* de preprocesamiento basado en MediaPipe Holistic; (3) entrenar y comparar arquitecturas LSTM, GRU y *transformers* ligeros sobre secuencias de *keypoints*; y (4) medir latencia, F1, *accuracy* y consumo energético del modelo desplegado en hardware tipo Raspberry Pi 4/5.

1.2 Justificación del enfoque y del uso de datasets públicos

Trabajar con vectores de coordenadas (x, y, z) en lugar de tensores RGB reduce la entrada de millones de píxeles a unas centenas de coordenadas por fotograma, lo cual habilita el despliegue en plataformas embebidas y garantiza la **agnostividad de hardware**. La elección de datasets públicos sobre captura propia se justifica por tres razones: (i) son *benchmarks* reconocidos que permiten comparación justa con el estado del arte; (ii) reducen riesgos de captura (heterogeneidad, sesgos, costos, dilemas éticos); y (iii) los repositorios con DOI persistente alinean el trabajo con los principios FAIR (Wilkinson et al., 2016) y con el estándar *Datasheets for Datasets* (Gebru et al., 2021).

1.3 Metodología de búsqueda y criterios de selección

La búsqueda se realizó entre febrero y abril de 2026 en Zenodo, Kaggle, ScienceDB, Mendeley Data, Figshare y Hugging Face, complementada con consultas en Scopus y Google Scholar mediante ("Mexican Sign Language" OR "LSM") AND (dataset OR corpus). Se aplicaron los cinco criterios mínimos exigidos: disponibilidad pública con DOI o URL persistente, pertinencia directa al tema, evidencia de uso en literatura JCR/IEEE/Springer en los últimos cinco años, licencia documentada y posibilidad técnica de descarga. Los cinco conjuntos seleccionados cubren tres modalidades complementarias —imágenes estáticas, video dinámico y texto—, lo que sustenta el enfoque multimodal propuesto.

2 Fichas técnicas de los cinco datasets seleccionados

2.1 D1 · Lengua de Señas Mexicana (~100 000 fotos) — Montesinos

Identificación. *Lengua de Señas Mexicana* (~100 000 fotos) (acrónimo de trabajo: LSM-100K-OM); autor: Osvaldo Montesinos; año: 2022; repositorio: Kaggle Datasets; URL persistente: <https://www.kaggle.com/datasets/osvalmontesinos/lengua-de-seas-mexicana-100000-fotos>; licencia: términos de uso de Kaggle (uso académico permitido bajo atribución; sin licencia Creative Commons explícita).

Origen y proceso de creación. Corpus de imágenes capturadas con cámara convencional bajo iluminación ambiental, con variación de fondos e iluminación entre tomas. La organización por carpetas hace que el nombre de la carpeta funcione como etiqueta de clase (letras del alfabeto, dígitos y palabras). No se reportan protocolos formales de aprobación ética.

Especificaciones técnicas. Aproximadamente 100 000 imágenes RGB en formato JPG, distribuidas en clases que cubren letras, dígitos y palabras simples; resolución uniforme tras preprocesamiento (224×224 px); tamaño descomprimido superior a 1 GB. Idioma de las etiquetas: español. Estructura <raíz>/<clase>/<archivo>.jpg.

Etiquetas y particiones. Clasificación multiclase con etiquetas inferidas del nombre de la carpeta; sin archivos de anotación independientes ni métricas de acuerdo entre anotadores. Sin particiones oficiales; se propone *split* estratificado 70/15/15 con `random_state=42`.

Casos de uso reportados. Citado en trabajos recientes de reconocimiento de LSM con CNNs y *pipelines* basados en MediaPipe (Sánchez-Vicinaiz et al., 2024); Ríos-Figueroa et al. (2022) reportan *accuracy* superiores al 90 % con arquitecturas comparables sobre subconjuntos del alfabeto estático.

Limitaciones y consideraciones éticas. (i) Ausencia de licencia Creative Commons explícita exige citar al autor y restringir el uso a fines académicos; (ii) condiciones de captura no uniformes; (iii) no se documenta el perfil demográfico de los *signers*.

Análisis exploratorio (EDA). Por restricciones computacionales locales, el análisis se realizó sobre una muestra balanceada estratificada de 200 imágenes (100 por clase, dos clases iniciales a y b). La Figura 1 confirma un balance perfecto y revela un **patrón bimodal** en la distribución de brillo medio: un primer modo en intensidades 40–55 (≈ 96 imágenes en condiciones de baja iluminación) y un segundo modo entre 100–155 (≈ 90 imágenes con iluminación intensa).




Figure 1: EDA del dataset D1 (Montesinos, 2022) sobre muestra estratificada de 200 imágenes: balance perfecto entre clases y distribución bimodal del brillo medio. Fuente: elaboración propia.

Estadística descriptiva. Sobre la muestra de $n = 200$, el brillo medio presenta $\bar{X} = 81.97$ con

$\sigma = 39.73$ e $IC_{95\%} = [76.46, 87.47]$. Resolución uniforme 224×224 px en el 100 % de la muestra. La prueba de Shapiro–Wilk rechaza normalidad ($W \approx 0.81$, $p < 10^{-4}$), consistente con la bimodalidad. Razón de imbalance: 1.00; entropía normalizada $H_n = 1.000$.

Hallazgos clave: (1) balance ideal de la muestra; (2) resolución uniforme indica preprocesamiento previo del autor para uso con redes preentrenadas tipo ResNet/MobileNet; (3) bimodalidad fotométrica sugiere usar normalización local (CLAHE) en lugar de global durante el entrenamiento; (4) el análisis sobre 200 imágenes caracteriza propiedades fotométricas pero no la cobertura léxica completa.

2.2 D2 · LSM Lenguaje de señas mexicanas — Chacon Quintero *et al.*

Identificación. Autores: J.C. Chacon Quintero, H. Martinez Nimi, S. Seira y A. Betanzo (UDEM/Chiba University); año: 2022; repositorio: Zenodo (versión 0.1); DOI: 10.5281/zenodo.6554337; URL: <https://doi.org/10.5281/zenodo.6554337>; licencia: CC-BY 4.0.

Origen y proceso de creación. Corpus elaborado por un equipo binacional México-Japón mediante la grabación de aproximadamente 400 videos de *signers* ejecutando números, letras y palabras simples; los fotogramas se extrajeron y serializaron en archivos `.pickle`. El registro en Zenodo otorga DOI persistente (FAIR).

Especificaciones técnicas. Distribución en archivos `.pickle` con frames serializados como `PIL.PngImageFile`. Subset *ABECEDARIO*: 72 imágenes RGB de 640×360 px (49.8 MB). Subset *PALABRAS*: 80 etiquetas + imágenes (221 MB). Subset *NUMEROS*: vacío en la versión 0.1. Tamaño total ≈ 271 MB.

Etiquetas y particiones. Identificadores ordinales (`1.png...72.png`) sin mapeo semántico explícito a las letras. Sin particiones oficiales; se propone 70/15/15 con `GroupKFold` agrupando por video.

Casos de uso reportados. Morfin-Chavez et al. (2023) discuten estrategias de *fingerspelling* aplicables; Mejía-Pérez et al. (2022) reportan *accuracy* $>95\%$ en alfabeto estático sobre conjuntos comparables.

Limitaciones. (i) Volumen moderado; (ii) diversidad demográfica no documentada; (iii) las imágenes son visualizaciones renderizadas de *keypoints* MediaPipe Holistic, no fotografías RGB —hallazgo crítico que alinea el dataset con el *pipeline* embebido propuesto.

Análisis exploratorio (EDA). La inspección programática confirma 72 imágenes RGB de 640×360 px en `PngImageFile`. El EDA se reformuló empleando variables geométricas: porcentaje de área activa, centroides (x, y) normalizados, extensión espacial y número de componentes conexos.




Figure 2: EDA del dataset D2 (Chacon Quintero *et al.*, 2022): las imágenes son keypoints MediaPipe sobre fondo blanco; t-SNE muestra separación del bloque ordinal B_5 . Fuente: elaboración propia.

Estadística descriptiva. El porcentaje promedio de área activa es $\bar{X} = 0.689\%$ con $IC_{95\%} = [0.683, 0.695]$ ($n = 72$). El número de componentes conexos detectados es $\bar{X} = 47.97$ con $IC_{95\%} = [47.52, 48.42]$, consistente con la suma de grupos faciales, manuales y corporales de MediaPipe Holistic. Las pruebas de Shapiro–Wilk rechazan normalidad ($p < 10^{-3}$) excepto para el conteo de componentes ($p = 0.054$).

Table 1: Estadística descriptiva de variables geométricas del dataset D2 (Chacon *et al.*, 2022).

Variable	n	Media	Mediana	Std	Min	Max	$IC_{95\%}$ inf	$IC_{95\%}$ sup
pct_activo	72	0.689	0.696	0.025	0.625	0.739	0.683	0.695
centroide_x	72	0.551	0.552	0.013	0.525	0.592	0.548	0.554
centroide_y	72	0.367	0.365	0.025	0.340	0.466	0.361	0.373
extension_x	72	0.383	0.377	0.018	0.375	0.458	0.379	0.388
extension_y	72	0.593	0.592	0.023	0.547	0.739	0.587	0.598
n_componentes	72	47.97	48.00	1.92	44.00	54.00	47.52	48.42

Hallazgos clave: (1) modalidad real son *keypoints* MediaPipe —no fotografías RGB—, alineando el dataset con el preprocesamiento de la tesis; (2) resolución uniforme 640×360 RGB; (3) etiquetas no semánticas requieren etiquetado manual asistido; (4) subset NUMEROS vacío; (5) balance ordinal aceptable (razón 2.33, entropía 0.937).

2.3 D3 · Mexican Sign Language Dataset — warcoder

Identificación. Autor: usuario *warcoder* en Kaggle; año: 2023; repositorio: Kaggle Datasets; URL: <https://www.kaggle.com/datasets/warcoder/mexican-sign-language-dataset>; licencia: términos de uso de Kaggle. Por estructura coincide con Espejel-Cabrera *et al.* (2024) (Mendeley Data, DOI 10.17632/6rj76z6y3n.1, CC-BY 4.0).

Origen y proceso de creación. Recopilación con cámara convencional bajo iluminación controlada y fondos uniformes; estructura por carpetas como etiqueta de clase. Aproximadamente 31 442 imágenes, 249 palabras, 11 sujetos según la fuente verificada.

Especificaciones técnicas. Imágenes RGB en JPG/PNG distribuidas por carpetas. Estructura jerárquica `<raíz>/<clase>/<archivo>`, compatible con cargadores estándar.

Etiquetas y particiones. Clasificación multiclase (alfabeto y palabras o gestos comunes). Sin métricas de acuerdo entre anotadores ni perfil demográfico. Sin particiones oficiales; se propone 70/15/15 estratificado.

Casos de uso. Empleado en cuadernos públicos de Kaggle con CNNs y arquitecturas ligeras tipo MobileNet. Trabajos académicos sobre *fingerspelling* con MediaPipe (Sánchez-Vicinaiz et al., 2024) reportan *accuracy* en torno al 83 %.

Limitaciones. (i) Ausencia de licencia explícita; (ii) falta de documentación demográfica; (iii) posible redundancia con D1 y D2. Se reserva como prueba de robustez (*out-of-distribution*).

Análisis exploratorio (EDA). Por restricciones computacionales el análisis se realizó sobre una muestra estratificada de 25 imágenes (5 clases $\times$ 5 imágenes) con `random_state=42`. La Figura 3 confirma balance perfecto y presenta el histograma del brillo medio, con patrón bimodal: cluster bajo (31–33, $n = 5$) y cluster mayoritario (38–41, $n = 20$).




Figure 3: EDA del dataset D3 (warcoder, 2023) sobre muestra estratificada: balance perfecto y distribución bimodal del brillo. Fuente: elaboración propia.

Estadística descriptiva. Sobre $n = 25$, el brillo medio presenta $\bar{X} = 37.52$ con $\sigma = 3.31$ e $IC_{95\%} = [36.22, 38.82]$. $CV = 8.81\%$. La prueba de Shapiro–Wilk rechaza normalidad ($W \approx 0.74$, $p < 10^{-3}$). Las imágenes del cluster bajo no son outliers sino un segundo modo legítimo.

Hallazgos clave: (1) balance perfecto en la muestra ($H_n = 1.000$); (2) bimodalidad fotométrica pese al control declarado; (3) no normalidad obliga a usar pruebas no paramétricas; (4) implicación: usar técnicas locales (CLAHE) y/o estratificar por iluminación; (5) limitación reconocida: $n = 25$ es exploratorio, el *pipeline* completo procesará el dataset entero.

2.4 D4 · MSL Alphabet (dynamic only) — Sánchez-Vicinaiz *et al.*

Identificación. Autores: T.J. Sánchez-Vicinaiz, E. Camacho-Pérez, A.A. Castillo-Atoche, M. Cruz-Fernandez, J.R. García-Martínez y J. Rodríguez-Reséndiz; año: 2025; repositorio: Zenodo; DOI: 10.5281/zenodo.14689869; URL: <https://doi.org/10.5281/zenodo.14689869>; licencia: CC-BY 4.0.

Origen y proceso de creación. Producido para complementar el corpus estático cubriendo las letras dinámicas: J, K, Ñ, Q, X y Z. Captura con *green screen* e iluminación uniforme; participaron 20 sujetos. Convención: S<SubjectId>-<Letter>-<View>-<RepNum>.

Especificaciones técnicas. Modalidad: video. Cobertura: 6 letras dinámicas; 20 participantes; múltiples vistas y repeticiones. Tamaño ≈ 3.6 GB.

Etiquetas y particiones. Clasificación de 6 clases. Particiones oficiales: **train/** (18 sujetos) y **test/** (2 sujetos), separación que evita fuga de información. Validación interna: **LeaveOneSubjectOut** sobre los 18 sujetos.

Casos de uso. Los autores reportan *accuracy* cercana al 83 % en *fingerspelling* dinámico con MediaPipe + redes neuronales (Sánchez-Vicinaiz et al., 2024).

Limitaciones. (i) Solo 6 clases; ideal como banco de pruebas del módulo temporal; (ii) *green screen* introduce sesgo de fondo, mitigable con aumentación; (iii) consentimiento de participantes documentado.

Análisis exploratorio (EDA). Por restricciones computacionales y el tamaño del corpus (≈ 3.6 GB), el análisis se realizó sobre 309 videos correspondientes a 3 letras (J, K, Ñ) procesados con OpenCV. La Figura 4 muestra una distribución bimodal: modo en ~ 1.5 s (señas con trazo único) y modo en ~ 2.1 s (señas con doble repetición).




Figure 4: EDA del dataset D4 (Sánchez-Vicinaiz et al., 2025): distribución bimodal de la duración consistente con dos patrones de articulación; cobertura del EDA local respecto al volumen declarado. Fuente: elaboración propia.

Estadística descriptiva. Sobre $n = 309$ videos, la duración media es $\bar{X} = 1.749$ s con $\sigma = 0.590$ s, mediana $Md = 1.703$ s e $IC_{95\%} = [1.683, 1.815]$ s. $CV = 33.72\%$. Rango $[0.580, 3.124]$ s; $IQR = 0.904$ s. Shapiro–Wilk rechaza normalidad ($W = 0.982$, $p = 0.00077$). Bajo IQR de Tukey no se detectaron outliers.

Hallazgos clave: (1) bimodalidad funcional (1.5 s vs 2.1 s) refleja patrones articulatorios; (2) duración media compatible con *fingerspelling* natural; (3) particiones oficiales por sujeto (18/2) se respetarán; (4) no normalidad requiere transformaciones logarítmicas o pruebas no paramétricas; (5) cobertura parcial: 3 de 6 letras procesadas localmente.

2.5 D5 · Spanish to MSL glosses corpus — Lara-Ortiz et al.

Identificación. Autores: V. Lara-Ortiz, R.Q. Fuentes-Aguilar e I. Chairez (Tecnológico de Monterrey); año: 2025; repositorio principal: ScienceDB; mirror Figshare 10.6084/m9.figshare.28519580; URL: <https://www.scidb.cn/en/detail?dataSetId=331676b05d494918970c6946bf37c7eb>; artículo: *Scientific Data*, vol. 12, art. 702 (2025), DOI 10.1038/s41597-025-04871-7; licencia: CC-BY 4.0.

Origen y proceso de creación. Corpus para entrenar y evaluar sistemas de traducción automática neuronal entre español y LSM en glosas. Metodología: consulta de manuales gramaticales y asesoría de intérpretes profesionales. Validación con dos modelos (Helsinki-NLP/opus-mt-es-es y BARTO) reporta BLEU 91.13 y 94.23 respectivamente; validación humana de 94 % (Lara-Ortiz et al., 2025).

Especificaciones técnicas. Corpus textual paralelo. 3 000 pares de oraciones español→LSM. Formato: `.xlsx` con dos columnas alineadas (`esp`, `lsm`).

Etiquetas y particiones. La etiqueta es la oración objetivo en glosa LSM, definiendo una tarea *sequence-to-sequence*. Glosado realizado por intérpretes profesionales. Sin particiones oficiales; se propone 80/10/10 estratificado por longitud con `random_state=42`.

Casos de uso. Los autores validan con scores BLEU al entrenar dos transformadores neuronales (Lara-Ortiz et al., 2025); trabajos previos sobre el lado complementario (Sánchez-Vicinaiz et al., 2024; Morfin-Chavez et al., 2023) convierten a este corpus en el complemento natural lingüístico del intérprete propuesto.

Limitaciones. (i) Tamaño modesto sugiere uso con *transfer learning*; (ii) registro tiende al formal por origen en libros gramaticales; (iii) licencia CC-BY 4.0.

Análisis exploratorio (EDA). La inspección de `esp-lsm_glosses_corpus.xlsx` confirma 3 000 pares paralelos sin valores nulos. Se detectaron 127 filas duplicadas exactas (4.2 %) que reflejan formas flexivas del español que colapsan en una misma glosa LSM (ej. *ve, vete, vas* → *tú ir*).




Figure 5: EDA del dataset D5 (Lara-Ortiz *et al.*, 2025): compresión léxica del español hacia LSM; la palabra *mujer* es la más frecuente en LSM por su rol como marcador analítico de género femenino. Fuente: elaboración propia.

Estadística descriptiva. La oración promedio en español contiene $\bar{X}_{SPA} = 3.959$ palabras ($IC_{95\%} = [3.902, 4.015]$, $n = 3000$) frente a $\bar{X}_{MSL} = 3.632$ palabras ($IC_{95\%} = [3.585, 3.679]$); intervalos no traslapados confirman diferencia significativa. Compresión léxica media: $\Delta = +0.327$ palabras ($IC_{95\%} = [0.289, 0.364]$). Vocabulario: 813 tipos en español (TTR= 0.0685, hapax 31.6 %) vs 620 en LSM (TTR= 0.0569, hapax 28.5 %): vocabulario más cerrado en LSM. Correlación de Pearson entre longitudes: $r = 0.749$. Shapiro–Wilk rechaza normalidad ($p < 10^{-3}$) en todas las métricas, consistente con la ley de Zipf.

Hallazgos clave: (1) compresión SOV cuantificada: la glosa LSM omite en promedio 0.33 palabras por oración; (2) marcación analítica del género femenino: *mujer* es la más frecuente en LSM por bigramas como *tío mujer* (= tía); (3) vocabulario más cerrado facilita aprendizaje supervisado con menos datos; (4) los 127 duplicados son productivos lingüísticamente y no deben eliminarse; (5) distribuciones no normales exigen herramientas no paramétricas.

3 Análisis comparativo entre los cinco datasets

3.1 Tabla comparativa con criterios homogéneos

La Tabla 2 sintetiza los cinco conjuntos frente a criterios homogéneos.

Table 2: Comparación homogénea de los cinco datasets seleccionados.

Criterio	D1 Montesinos	D2 Chacon	D3 warcoder	D4 DynAlph	D5 Glosses
Año	2022	2022	2023	2025	2025
Volumen	~100K imgs	72+80 imgs	~31K imgs	20 sujetos × 6 letras	3 000 pares
Modalidad	Imagen RGB	Keypoints rend.	Imagen RGB	Video	Texto paralelo
Idioma	ES	ES (ord.)	ES	N/A gestual	ES → glosa
Repositorio	Kaggle	Zenodo	Kaggle	Zenodo	ScienceDB/Figshare
DOI persistente	No	Sí	No	Sí	Sí
Licencia	Kaggle ToU	CC-BY 4.0	Kaggle ToU	CC-BY 4.0	CC-BY 4.0
Splits oficiales	No	No	No	Sí (18/2)	No
Lit. JCR/IEEE	Sí	Sí	Sí (indir.)	Sí	Sí
Ajuste a tesis	Alto (volumen)	Medio (anot.)	Bajo (redund.)	Alto (temporal)	Alto (lingüístico)

3.2 Lectura crítica

Volumen. D1 (Montesinos) es el más voluminoso y por sí solo justifica entrenamientos profundos de clasificación estática. D2 y D3 son moderados, útiles como validación externa. D4 es pequeño en clases (6) pero rico en variabilidad inter-sujeto. D5, con 3 000 pares, es modesto en volumen pero excepcional en calidad lingüística.

Modalidad y complementariedad. D1, D2 y D3 cubren la modalidad estática; D4 aporta la dimensión temporal por video; D5 introduce la dimensión lingüística-textual. Esta heterogeneidad refleja el carácter **multimodal** del intérprete propuesto.

Reproducibilidad y trazabilidad. D2, D4 y D5 cuentan con DOI persistente (FAIR). D1 y D3, en Kaggle, ofrecen URL persistente pero carecen de DOI.

Licenciamiento. Tres datasets (D2, D4, D5) bajo CC-BY 4.0 dan seguridad jurídica para difusión académica. D1 y D3 se rigen por términos de Kaggle.

3.3 Recomendación final

Dataset principal: D1 — Montesinos. Su volumen permite entrenar redes profundas de clasificación visual con suficiente capacidad de generalización a las señas estáticas, núcleo del módulo perceptual. Como mitigación del licenciamiento, los pesos del modelo se distribuirán bajo *model card* con cita explícita y restricción a fines académicos.

Dataset complementario: D5 — Lara-Ortiz *et al.* Aporta el componente lingüístico que mapea la salida visual del modelo a una glosa correctamente ordenada según la sintaxis SOV de la LSM y, posteriormente, a texto en español o a voz mediante TTS. Su licencia CC-BY 4.0 y publicación en *Scientific Data* respaldan su empleo en una tesis indexable.

D2 y D4 actúan como conjuntos de validación externa (D2 para generalización a corpus de origen

distinto; D4 para validar el módulo temporal en *fingerspelling* dinámico). D3 se reserva como *out-of-distribution set* para auditar robustez.

4 Reflexión y plan de uso

4.1 Integración de los datasets en el *pipeline* de la tesis

El *pipeline* se organiza en cuatro etapas. (1) **Adquisición y preprocesamiento**: las imágenes y videos de D1, D2, D3 y D4 se procesan con MediaPipe Holistic (Lugaresi et al., 2019; Zhang et al., 2020) para extraer 543 *keypoints* —468 faciales, 21 por mano y 33 corporales— por fotograma, transformando cada muestra visual en un tensor compacto de coordenadas. (2) **Modelado perceptual**: se entrenan y comparan arquitecturas LSTM, GRU y *transformers* ligeros sobre las secuencias. (3) **Traducción lingüística**: el corpus D5 entrena un modelo *sequence-to-sequence* que mapea glosas a español natural. (4) **Síntesis**: módulo TTS estándar convierte texto a voz.

4.2 Validación cruzada y métricas

Sobre D1 y D3 se aplica **StratifiedKFold** con $k = 5$. Sobre D2 se utiliza **GroupKFold** agrupando por video. Sobre D4 se respeta la partición oficial 18/2 y se complementa con **LeaveOneSubjectOut**. Sobre D5 se emplea 80/10/10 estratificada por longitud. En todos los casos se fija **random_state=42**. Para clasificación visual se reportan *accuracy*, F1 macro y matriz de confusión; para D4 se añade F1 ponderado y tiempo de inferencia; para D5 se reportan BLEU y chrF. Adicionalmente, métricas de eficiencia en hardware embebido: latencia media, FPS sostenidos, consumo energético por inferencia (J) y memoria RAM pico.

4.3 Limitaciones, sesgos y consideraciones éticas globales

A nivel de proyecto persisten tres sesgos identificables. (i) *Sesgo de signer*: ningún dataset documenta exhaustivamente la diversidad demográfica de los participantes. (ii) *Sesgo de captura*: las condiciones de iluminación, fondo y resolución difieren entre datasets; se controlan mediante aumentación y normalización por *keypoints*. (iii) *Sesgo lingüístico*: D5, derivado de manuales gramaticales, sobrerrepresenta el registro formal. Como mitigación, los pesos del modelo final se documentarán con una *model card* (Geburu et al., 2021), se publicarán únicamente pesos y código (no los corpus reempaquetados), y se invitará a la comunidad sorda mexicana a evaluar el sistema en una fase posterior.

4.4 Conclusión

La selección argumentada de los cinco datasets cubre las tres modalidades exigidas por un intérprete multimodal de LSM —imagen estática, video dinámico y corpus textual— y respeta los criterios de licenciamiento, indexación científica y reproducibilidad. El uso de MediaPipe Holistic como capa de preprocesamiento alinea la tesis con su objetivo central de ingeniería electrónica: ejecutar un intérprete robusto sobre hardware embebido de bajo consumo, sin renunciar a la riqueza de los marcadores gramaticales no manuales. Los *notebooks* de EDA, los *scripts* de entrenamiento y la documentación complementaria se publican en un repositorio público bajo control de versiones, garantizando la trazabilidad técnica que exige el programa de Ingeniería Electrónica de la FIAD-UABC.

Referencias bibliográficas

- Espejel-Cabrera, J., Cervantes, J., García-Lamont, F., et al. (2024). Mexican sign language images dataset for word-level sign recognition. *Data in Brief*, 55:110566.
- Gebru, T., Morgenstern, J., Vecchione, B., et al. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12):86–92.
- Instituto Nacional de Estadística y Geografía (2020). Censo de población y vivienda 2020: Discapacidad. INEGI.
- Lara-Ortiz, V., Fuentes-Aguilar, R. Q., and Chairez, I. (2025). Spanish to Mexican Sign Language (MSL) glosses corpus for natural language processing tasks. *Scientific Data*, 12:702.
- Lugaresi, C., Tang, J., Nash, H., et al. (2019). MediaPipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*.
- Mejía-Pérez, K. et al. (2022). Automatic recognition of Mexican Sign Language using a depth camera and a recurrent neural network. In *IEEE SMC*.
- Morfin-Chavez, R. et al. (2023). Fingerspelling recognition in Mexican Sign Language using machine learning. *Engineering Applications of Artificial Intelligence*.
- Ríos-Figueroa, H. V. et al. (2022). Spherical and translation-invariant features for the recognition of static signs in Mexican Sign Language. *Computación y Sistemas*.
- Serafín de Fleischmann, M. E. and González Pérez, R. (2011). *Manos con voz: Diccionario de Lengua de Señas Mexicana*. CONAPRED, Ciudad de México.
- Sánchez-Vicinaiz, T. J., Camacho-Pérez, E., Castillo-Atoche, A. A., Cruz-Fernandez, M., García-Martínez, J. R., and Rodríguez-Reséndiz, J. (2024). MediaPipe frame and convolutional neural networks-based fingerspelling detection in Mexican Sign Language. In *Proceedings IEEE*.
- Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., et al. (2016). The FAIR guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018.
- Zhang, F., Bazarevsky, V., Vakunov, A., et al. (2020). MediaPipe hands: On-device real-time hand tracking. *arXiv preprint arXiv:2006.10214*.